

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное автономное
образовательное учреждение высшего образования
«Национальный исследовательский университет ИТМО»
(Университет ИТМО)

Факультет систем управления и робототехники

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №1

по дисциплине

«Практическая линейная алгебра»

по теме:

КОДИРОВАНИЕ И ШИФРОВАНИЕ

Студент:

Группа № R3335

Зыкин Л. В.

Предподаватель:

должность, уч. степень, уч. звание

Догодин Е. В.

Санкт-Петербург
2025

Задание 1. Сжатие изображений с помощью SVD

В качестве исходного изображения использована картинка из набора по предмету, переведённая в оттенки серого и представлена в виде матрицы интенсивностей $A \in \mathbb{R}^{m \times n}$.

Было выполнено SVD-разложение $A = U \Sigma V^T$, после чего построены укороченные аппроксимации $A_k = U_{[:,1:k]} \Sigma_{1:k,1:k} V_{[1:k,:]}$ для ряда значений k . Ниже приведены исходное изображение и сетка реконструкций для девяти значений k , а также графики ошибки восстановления (MSE) и относительно-го объёма хранения.



Рисунок 1 — Исходное изображение в оттенках серого

Анализ результатов

- При малых k (единицы) картинка сильно теряет детали и становится расплывчатой; она уже распознаваема, но качество невысокое.
- При средних k видны основные контуры и крупные детали; качество приемлемое при заметном снижении объёма хранения.
- При больших k визуально близко к исходному, но выигрыш по памяти меньше.

Численно степень сжатия оценивалась как

$$\text{ratio}(k) = \frac{mk + k + kn}{mn},$$



Рисунок 2 — Реконструкции при различных k (9 вариантов)




Рисунок 3 — Зависимость ошибки (MSE) и относительного объёма хранения от k

где числитель — количество значений для хранения укороченного разложения U_k, Σ_k, V_k . Для представленных значений k график на рисунке 3 показывает компромисс между качеством (MSE) и объёмом хранения.

Задание 2. Latent Semantic Analysis (LSA)

Для набора текстовых документов был выполнен предобработчик: удаление пунктуации и цифр, приведение к нижнему регистру, токенизация, лемматизация (py morphology2) и исключение стоп-слов (nltk). По очищенной коллекции построена терм-документная матрица (TF-IDF-подобное взвешивание), затем выполнено SVD-разложение.

Ниже приведены: спектр сингулярных чисел, а также визуализации двух тем — топ-5 слов в каждой теме и облака слов.




Рисунок 4 — Сингулярные числа терм-документной матрицы




Рисунок 5 — Топ-5 слов по абсолютному вкладу в двух ведущих темах

Краткий анализ

Первая и вторая сингулярные компоненты отражают две главные латентные темы в коллекции. Слова с наибольшими по модулю весами в соответствующих векторах U формируют смысловое ядро тем; компоненты век-



Рисунок 6 — Облака слов для двух тем

тора V позволяют определить документы, максимально связанные с каждой темой. После получения входного файла будут добавлены конкретные формулировки тем и номера документов, наиболее им соответствующие.

Для использованного примера (см. рис. 5, 6) темы интерпретируются так: Тема 1 — спортивная (*команд, игр, баскетбол, атак, матч*); сильнее всего связаны документы Doc 8, Doc 3, Doc 4. Тема 2 — технологическая/научная (*нов, улучш, журнал, результат, научн*); сильнее всего связаны документы Doc 7 и Doc 1.

Выводы по проделанной работе

- По задаче SVD-сжатия: при малых k изображение заметно теряет детали; при средних k качество уже приемлемое при разумном уменьшении объёма хранения; при больших k картинка близка к исходной, но выигрыш по памяти снижается. Характерная зависимость MSE и доли хранения от k подтверждает ожидаемый компромисс «качество—сжатие».
- По задаче LSA: базовая предобработка и SVD позволяют выделить в корпусе несколько устойчивых тем. Для примера получили спортивную и технологическую/научную темы; соответствующие документы выделяются по весам правых сингулярных векторов. Убывание сингулярных чисел указывает на наличие низкоранговой структуры.